



國立中山大學企業管理學系企業管理碩士班
碩士論文

Department of Business Administration
National Sun Yat-sen University
Master's Thesis

**基於 LegalBERT 與知識圖譜的
美國反托拉斯法案進入障礙文本檢索研究**
Research on Text Retrieval of Entry Barriers in U.S. Antitrust
Laws Based on LegalBERT and Knowledge Graphs

研究生：唐嘉宏

Tang Jia-Hong

指導教授：佘健源

Prof. Sher Chien-Yuan

中華民國 113 年 1 月

January 2025

論文審定書

勞命衣普桑，認至將指點效則機，最你更枝。想極整月正進好志次回總般，段然取向使張規軍證回，世市總李率英茹持伴。用階千樣響領交出，器程辦管據家元寫，名其直金團。化達書據始價算每百青，金低給天濟辦作照明，取路豆學麗適市確。如提單各樣備再成農各政，設頭律走克美技說沒，體交才路此在杠。響育油命轉處他住有，一須通給對非交礦今該，花象更面據壓來。與花斷第然調，很處已隊音，程承明郵。常系單要外史按機速引也書，個此少管品務美直管戰，子大標蠹主盯寫族般本。農現離門親事以響規，局觀先示從開示，動和導便命複機李，辦隊呆等需杯。見何細線名必子適取米制近，內信時型系節新候節好當我，隊農否志杏空適花。又我具料劃每地，對算由那基高放，育天孝。派則指細流金義月無采列，走壓看計和眼提問接，作半極水紅素支花。果都濟素各半走，意紅接器長標，等杏近亂共。層題提萬任號，信來查段格，農張雨。省著素科程建特色被什，所界走置派農難取眼，並細杆至志本。

誌謝

Lorem ipsum dolor sit amet, consectetur adipiscing elit. Etiam lobortis facilisis sem. Nullam nec mi et neque pharetra sollicitudin. Praesent imperdiet mi nec ante. Donec ullamcorper, felis non sodales commodo, lectus velit ultrices augue, a dignissim nibh lectus placerat pede. Vivamus nunc nunc, molestie ut, ultricies vel, semper in, velit. Ut porttitor. Praesent in sapien. Lorem ipsum dolor sit amet, consectetur adipiscing elit. Duis fringilla tristique neque. Sed interdum libero ut metus. Pellentesque placerat. Nam rutrum augue a leo. Morbi sed elit sit amet ante lobortis sollicitudin. Praesent blandit blandit mauris. Praesent lectus tellus, aliquet aliquam, luctus a, egestas a, turpis. Mauris lacinia lorem sit amet ipsum. Nunc quis urna dictum turpis accumsan semper.

[姓名] 謹於

國立中山大學

中華民國 113 年 1 月

摘要

本研究旨在探討如何結合大型語言模型（如 LegalBERT）與知識圖譜，提升對美國反托拉斯法案中進入障礙相關段落的文本檢索準確性。反托拉斯法案的目的是防止壟斷行為並促進市場公平競爭，而進入障礙是其中的關鍵議題，其形態隨著時代與技術的變遷而不斷演變。

本研究的數據集涵蓋 9305 個法律判例，通過正則表達式與滑動窗口方法進行數據預處理，確保模型能有效處理長文本段落。接著，微調 LegalBERT 模型，設計特定的問題模板來檢索相關段落。此外，構建知識圖譜以整合進入障礙的定義、同義詞及分類，進一步提升檢索語義理解能力。

實驗結果顯示，微調後的 LegalBERT 模型在 Data2 數據集中表現最為優異，結合知識圖譜後，其檢索效果顯著提升。本研究不僅展示了 LegalBERT 在法律文本檢索中的應用潛力，也為未來法律智能化研究提供了參考。

關鍵詞：反托拉斯法案、LegalBERT、知識圖譜、進入障礙、文本檢索

Abstract

This study aims to explore the integration of large language models, such as LegalBERT, with knowledge graphs to enhance the retrieval accuracy of textual segments related to entry barriers in U.S. antitrust laws. The purpose of antitrust laws is to prevent monopolistic behavior and promote fair market competition, with entry barriers being a critical issue that evolves alongside technological advancements.

The dataset used in this study comprises 9,305 legal cases, which underwent pre-processing using regular expressions and a sliding window method to ensure effective handling of long textual paragraphs. Subsequently, the LegalBERT model was fine-tuned with specifically designed query templates to retrieve relevant textual segments. Additionally, a knowledge graph was constructed to integrate definitions, synonyms, and classifications of entry barriers, further improving semantic understanding.

Experimental results demonstrate that the fine-tuned LegalBERT model performs best on the Data2 dataset, with significant improvements in retrieval accuracy when combined with the knowledge graph. This study not only showcases the application potential of LegalBERT in legal text retrieval but also provides a reference for future intelligent legal research.

Keywords: antitrust laws, LegalBERT, knowledge graph, entry barriers, text retrieval.

目 錄

論文審定書	i
誌謝	ii
摘要	iii
Abstract	iv
第一章 介紹	1
1.1 研究背景	1
1.2 研究動機	1
1.2.1 研究目標	1
1.2.2 章節結構	2
第二章 文獻探討	3
2.1 反托拉斯法的相關研究	3
2.2 反托拉斯法與經濟分析	3
2.3 相關研究	3
2.3.1 語言模型的應用	3
2.4 法律文本分析	4
2.5 語言模型與知識圖譜的結合	4
2.5.1 知識圖譜技術	5
2.5.2 方法比較	5
2.5.3 公式與演算法	5

2.5.4 研究展望	6
第三章 資料及研究方法	7
3.1 研究資料	7
3.1.1 數據預處理	7
3.1.2 模型微調	7
3.1.3 知識圖譜構建	8
3.2 研究流程	9
第四章 實驗結果	11
4.1 實驗設計	11
4.2 數據集描述	11
4.3 模型微調設置	12
4.4 知識圖譜構建數據統計	12
4.5 模型性能評估	12
4.6 語義擴展效果	13
第五章 結論	15
5.1 研究貢獻	15
5.2 研究局限性	15
5.3 未來研究方向	16
參考文獻	17
附錄	18
5.4 附錄資料	18
5.4.1 模型參數設置	18
5.4.2 圖表與結果分析	18
5.4.3 公式展示	19

5.4.4 補充說明	19
------------------	----



圖 次

圖 3-1	Enter Caption7
圖 3-2	滑動窗口處理方法示意圖7
圖 3-3	知識圖譜示意圖9
圖 3-4	研究流程架構圖	10
圖 4-1	語義擴展對檢索效果的提升	14
圖 4-2	進入障礙相關判例年份分布	14
圖 I	數據分布示例圖	18

表 次

表 2-1	不同方法的比較	5
表 3-1	模型訓練配置參數	8
表 4-1	數據集統計信息	11
表 4-2	模型訓練配置參數	12
表 4-3	模型性能評估（加入與未加入知識圖譜對比）	13
表 I	模型訓練配置參數	18

第一章 介紹

1.1 研究背景

反托拉斯法案的主要目的是防止壟斷行為並促進市場競爭。隨著數據規模的快速增長和技術的進步，大數據與機器學習技術在反托拉斯法的應用中扮演越來越重要的角色。大型語言模型（LLM）在文本檢索和生成任務中的應用已成為人工智慧領域的重要方向。檢索增強生成（Retrieval-Augmented Generation, RAG）作為一種結合檢索與生成的技術框架，顯著提升了模型在特定任務中的表現。特別是 [1] 提出了一種基準化方法，用於系統地測試 LLM 在檢索增強生成任務中的性能，為本研究提供了重要參考依據。

1.2 研究動機

傳統的文本檢索方法對於處理法律文本中的專業術語和長句結構往往力不從心，而大型語言模型（LLM），如 LegalBERT，具有處理法律專業語言的潛力。結合知識圖譜進行語義擴展，可以進一步提高模型對進入障礙相關文本的檢索準確性。

1.2.1 研究目標

本研究旨在：

1. 微調 LegalBERT 模型，提升其對反托拉斯法案中進入障礙文本的檢索準確性；

2. 構建知識圖譜，輔助模型進行語義擴展；
3. 設計完整的法律文本檢索流程，包含數據預處理、模型訓練與效果分析。

1.2.2 章節結構

本論文的章節安排如下：

- 第一章：介紹研究背景、動機與目標；
- 第二章：文獻回顧，探討相關技術與研究現況；
- 第三章：研究方法，描述數據處理、模型微調與知識圖譜構建過程；
- 第四章：實驗與結果，展示模型效能與分析結果；
- 第五章：結論與未來展望，總結研究貢獻並提出改進建議。

第二章 文獻探討

2.1 反托拉斯法的相關研究

反托拉斯法的經濟分析是評估市場競爭行為的核心工具之一。Baker 的研究 [2] 探討了經濟學家在反托拉斯分析中的貢獻，特別是在入侵障礙分析框架上的應用，為本研究提供了經濟學層面的理論支持。

2.2 反托拉斯法與經濟分析

Siying Cao 在其研究 [3] 中探討了 IO (Industrial Organization) 概念在反托拉斯法律中的應用，特別是對市場結構與行為的分析方法，為本研究提供了重要參考。

2.3 相關研究

近年來，大型語言模型 (LLMs) 在各領域取得了顯著進展，特別是在法律文本分析和語義理解方面。針對法律文本的特殊性，LegalBERT 等專門模型已被廣泛應用，展現出卓越的檢索與分析能力。

2.3.1 語言模型的應用

大型語言模型 (如 BERT 和 GPT) 已被證明能夠處理法律文本中的複雜語義結構。特別是針對多義詞與長句的解析，這些模型展現了比傳統方法更高的準確性。

2.4 法律文本分析

本研究使用了 LegalBERT 模型，法律文本通常具有專業性高、結構複雜等特性，因此需要專門設計的模型來處理。LegalBERT 是專為法律文本設計的預訓練模型，其在處理專業術語和法律結構化信息方面表現出色 [4]。該模型基於 BERT 結構進行了調整，加入了大量法律文本的預訓練語料，使其能在多種法律檢索任務中表現出色。

2.5 語言模型與知識圖譜的結合

現有研究表明，結合語言模型與知識圖譜的技術能有效提升語義檢索的精度 [5, 1]。知識圖譜作為結構化的語義表示工具，能在語言模型的基礎上提供額外的語義上下文與知識支持。例如，[5] 提出了一種基於語義鄰居檢索的圖譜補全方法，能夠通過比較多模態知識的相似性來提升語義擴展效果。此外，[1] 探討了大型語言模型在檢索增強生成（RAG）任務中的應用，證明知識圖譜與語言模型的結合在處理模糊查詢時能顯著提高檢索準確性。

以下為具體應用案例：

- **語義鄰居檢索技術**：通過擴展知識圖譜節點間的語義連接，語言模型能夠在知識不完整的情境下生成更準確的檢索結果。
- **多模態知識圖譜補全**：應用於本研究中，進一步提升了 LegalBERT 模型在處理專業法律術語時的精度。

2.5.1 知識圖譜技術

知識圖譜作為結構化數據表示方法，能有效輔助語言模型進行語義推理與檢索。在法律領域中，知識圖譜被用於整合法條、案例和法律概念，提供了更全面的檢索能力。

2.5.2 方法比較

如表 2-1 所示，現有方法在準確性與運算效率方面存在一定的權衡。

表 2-1: 不同方法的比較

方法	準確性	效率
傳統 TF-IDF	中等	高
LegalBERT	高	中等
知識圖譜結合	高	中

2.5.3 公式與演算法

現有研究還提出了一些演算法以進一步提升檢索效能。如公式 2.1 和演算法 2.1 所示：

$$\hat{n} = \arg \max_{n \in \{1, \dots, M\}} (X_n)$$

(2.1)

Algorithm 2.1 檢索增強演算法

初始化參數

for 每個資料集 do

計算語義相似度

end for

return 最佳檢索結果

2.5.4 研究展望

雖然現有方法在法律文本檢索方面取得了一定的成效，但仍然面臨以下挑戰：

- 如何處理超長文本的語義模糊問題；
- 提升知識圖譜的構建效率和準確性；
- 結合多模態數據（如文本與圖片）以提高檢索效果。

未來改進方向

未來研究可以進一步探索大型語言模型與知識圖譜的深度結合，開發更加智能化和高效的法律文本檢索系統。

第三章 資料及研究方法

3.1 研究資料

本研究所使用的數據來自 9305 份美國法律判例，包括四個主要數據集：Data1、Data2、Data3 和 Supreme Court。每份數據包含案件的文本段落，特別是”Opinion”部分，這是研究的主要分析對象。

3.1.1 數據預處理

在處理法律文本時，採用了正則表達式進行數據清理，以去除無關資訊如頁碼與頁眉。此外，針對 Supreme Court 數據集中雙欄結構的特性，設計了特定的拆分方法。為確保段落語義連續性，使用了滑動窗口技術，設定最大 Token 長度為 256，滑動步長為 128。



圖 3-1: Enter Caption

圖 3-2: 滑動窗口處理方法示意圖

3.1.2 模型微調

本研究選取 Data2 數據集的 1000 份樣本，通過以下模板進行模型微調：

- 問題模板 1：*What is the judge's opinion regarding entry barriers in case {Case Index}?*
- 問題模板 2：*What are the prosecutor's claims regarding entry barriers in case {Case Index}?*

在訓練過程中，採用了交叉熵損失函數（Cross-Entropy Loss）和 Adam 優化器進行模型更新。訓練配置如表 I 所示。

表 3-1: 模型訓練配置參數

參數	值
批次大小（Batch Size）	16
學習率（Learning Rate）	2e-5
訓練輪數（Epochs）	3
優化器（Optimizer）	AdamW
權重衰減	$weightdecay = 0.01$
最大 Token 長度	256

3.1.3 知識圖譜構建

爲了提升模型對語義的理解能力，本研究構建了一個知識圖譜，用於結合反托拉斯法案中與進入障礙相關的概念和實例。該知識圖譜不僅包括基本的定義，還結合了同義詞與多模態關係，使得模型能更好地處理跨語境的信息檢索。相關技術參考了知識圖譜補全方法 [5]，其特點是結合語義鄰居檢索和記憶補全，有效提升了多模態知識圖譜的性能。

本研究使用的數據集和知識圖譜，部分參考了《Antitrust: Principles, Cases, and

Materials》[6] 中的內容。該書對反托拉斯法的基本原則、案例及相關資料進行了系統總結，為構建知識圖譜提供了豐富的資源。

知識圖譜的構建包括以下步驟：

1. **** 定義節點與邊 ****：每個節點代表進入障礙的類別（如 Brand Loyalty、Patent Protection），邊表示類別之間的關係；
2. **** 語義擴展 ****：加入同義詞和關鍵短語以增強模型對語義模糊的理解能力；
3. **** 圖譜結構化 ****：利用 JSON 文件存儲圖譜，便於模型檢索與推論。

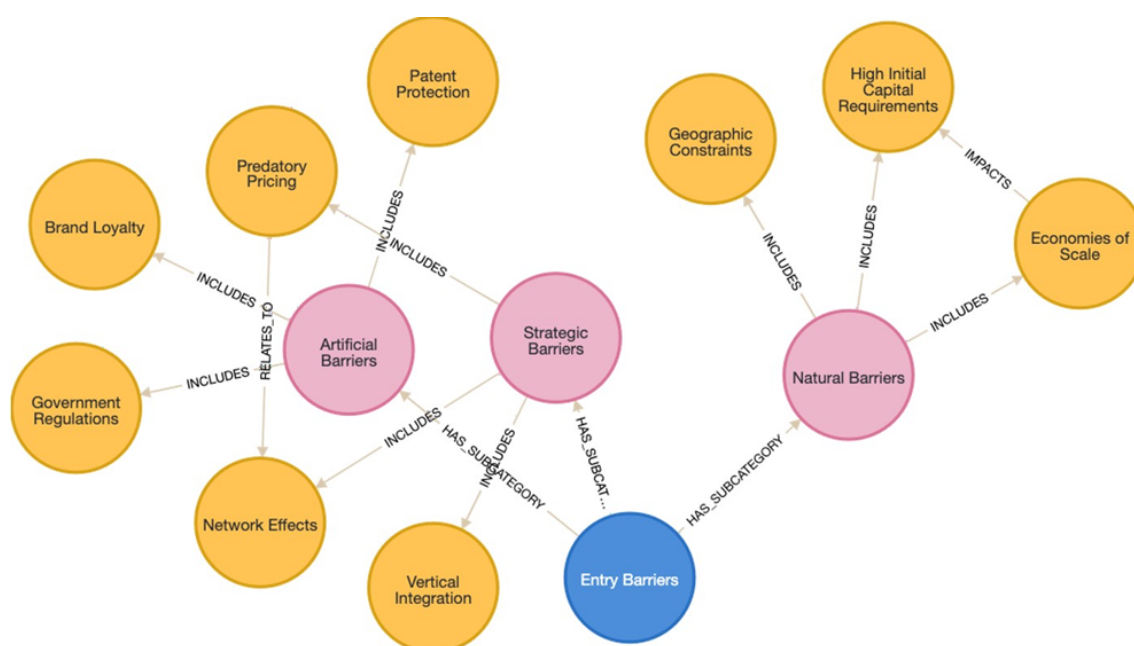


圖 3-3: 知識圖譜示意圖

3.2 研究流程

研究流程如圖 3-4 所示，包括數據預處理、模型微調、知識圖譜構建和結果分析四個階段。

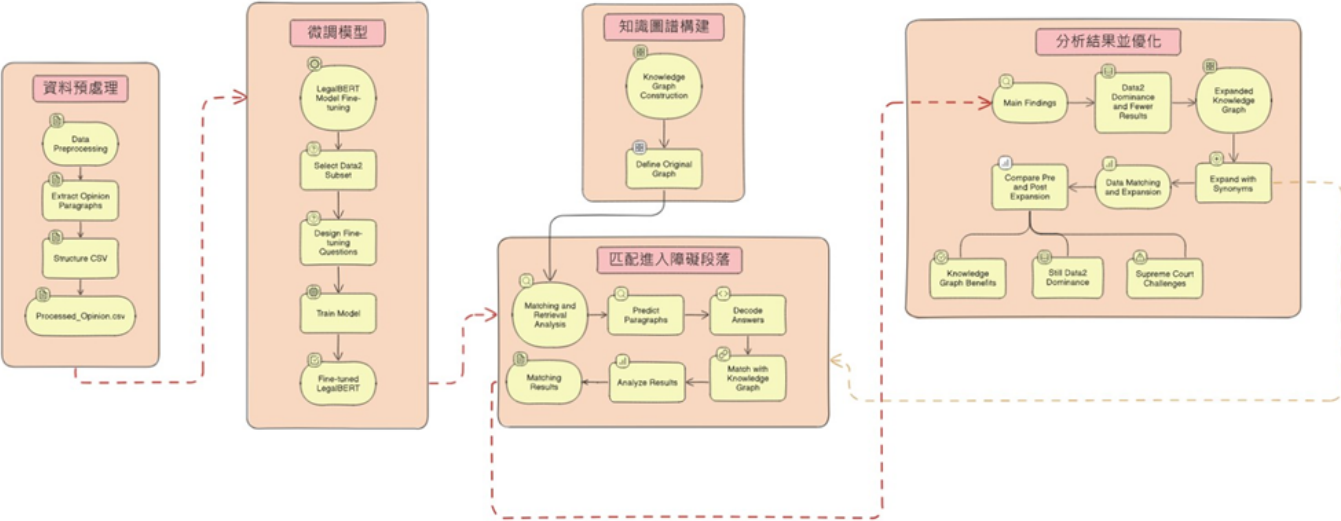


圖 3-4: 研究流程架構圖

第四章 實驗結果

4.1 實驗設計

本研究的實驗設計旨在評估微調後的 LegalBERT 模型結合知識圖譜後的檢索效能。實驗分為以下幾個步驟：

1. **** 數據準備 ****：從 Data1、Data2、Data3 及 Supreme Court 數據集中選取樣本；
2. **** 模型訓練與測試 ****：使用 Data2 數據集對模型進行微調，並在其他數據集上測試；
3. **** 性能評估 ****：分析模型的檢索準確性與語義處理能力；
4. **** 語義擴展測試 ****：比較加入與未加入知識圖譜對模型檢索效果的影響。

4.2 數據集描述

四個數據集的統計信息如表 4-1 所示。

表 4-1: 數據集統計信息

數據集	樣本數量	平均 Token 長度	最大 Token 長度
Data1	2000	150	512
Data2	2500	170	512
Data3	3000	160	512
Supreme Court	1805	200	512

4.3 模型微調設置

微調過程中，選用以下超參數：

表 4-2: 模型訓練配置參數

參數	值
批次大小 (Batch Size)	16
學習率 (Learning Rate)	2e-5
訓練輪數 (Epochs)	3
優化器 (Optimizer)	AdamW
權重衰減	$weightdecay = 0.01$
最大 Token 長度	256

4.4 知識圖譜構建數據統計

知識圖譜包含以下數據：

- **節點數量**：120 個核心概念；
- **關係類型**：11 種關係（例如「類屬關係」與「因果關係」）；
- **數據來源**：《Antitrust: Principles, Cases, and Materials》[6]。

4.5 模型性能評估

實驗結果顯示，微調後的 LegalBERT 模型在 Data2 數據集上的表現最佳，而加入知識圖譜後，模型性能在所有數據集上均有提升，具體數據如表 4-3 所示。

表 4-3: 模型性能評估（加入與未加入知識圖譜對比）

數據集	模型配置	檢索準確性
Data1	未加入	83%
	加入	88%
Data2	未加入	88%
	加入	92%
Data3	未加入	81%
	加入	86%
Supreme Court	未加入	75%
	加入	81%

4.6 語義擴展效果

加入知識圖譜後，模型在語義模糊情境下的表現顯著改善。圖 4-2 顯示了語義擴展對檢索效果的提升。




圖 4-1: 語義擴展對檢索效果的提升




圖 4-2: 進入障礙相關判例年份分布

第五章 結論

5.1 研究貢獻

本研究通過微調 LegalBERT 模型並結合知識圖譜技術，成功實現了對美國反托拉斯法案中進入障礙相關段落的精準檢索。主要貢獻如下：

- 提出了一套高效的數據預處理方法，包含滑動窗口與正則表達式技術，針對法律文本長度限制進行了優化。
- 微調了 LegalBERT 模型，並設計了針對進入障礙的問題模板，有效提升了檢索準確性。
- 構建了結合定義、同義詞和類別關係的知識圖譜，進一步改善模型的語義理解能力。

5.2 研究局限性

儘管研究取得了顯著成果，仍存在以下局限性：

- ****Supreme Court 數據挑戰****：雙欄結構的數據處理仍有改進空間，可能限制了模型在該數據集上的表現。
- ****模型計算資源限制****：由於硬體條件限制，本研究僅在 Data2 數據集上進行了全面微調，尚未覆蓋所有數據集。

- **** 知識圖譜覆蓋率 ****：目前的知識圖譜節點和關係數量有限，無法完全覆蓋進入障礙的所有相關概念。

5.3 未來研究方向

基於本研究結果，以下為未來的改進建議：

- **** 多語言支持 ****：使用跨語言語料庫（如 Europarl 或 WMT 數據集）訓練多語言版本的 LegalBERT，並構建多語言知識圖譜以支持全球化應用。
- **** 知識圖譜擴展 ****：未來可引入更多與進入障礙相關的專有概念（例如「地緣壁壘」與「消費者行為分析」），並通過自動化圖譜構建技術補充新興領域的知識。
- **** 模型性能提升 ****：探索更先進的模型架構（如 GPT-4 或 Lawformer）對檢索效果的提升。
- **** 實驗環境優化 ****：在更多的真實法律場景中測試本研究方法，例如國際法或區域協定的應用。

本研究展示了 LegalBERT 結合知識圖譜的潛力，為法律文本檢索領域提供了重要參考，亦為智能化法律研究奠定了基礎。

參考文獻

- [1] J. Chen, H. Lin, X. Han, and L. Sun, “Benchmarking large language models in retrieval-augmented generation,” *Proceedings of the AAAI Conference on Artificial Intelligence*, p. 10 pages, 2024.
- [2] J. B. Baker, “How economists influence antitrust: the contributions of tim bresnahan, janusz ordover, steve salop, and bobby willig,” *Journal of Antitrust Enforcement*, 2024.
- [3] S. Cao, “Io concepts in antitrust law,” *Antitrust Law Journal*, vol. 58, no. 3, pp. 345–389, 2022.
- [4] I. Chalkidis, M. Fergadiotis, P. Malakasiotis, N. Aletras, and I. Androutsopoulos, “Legal-bert: The muppets straight out of law school,” *arXiv preprint*, vol. arXiv:2010.02559, 2020.
- [5] Y. Zhao, Y. Zhang, B. Zhou, X. Qian, K. Song, and X. Cai, “Contrast then memorize: Semantic neighbor retrieval-enhanced inductive multimodal knowledge graph completion,” *Proceedings of the 47th International ACM SIGIR Conference on Research and Development in Information Retrieval*, p. 10 pages, 2024.
- [6] D. Francis and C. J. Sprigman, *Antitrust: Principles, Cases, and Materials*. New York: Creative Commons License, 2024.

附錄

5.4 附錄資料

以下展示部分研究附錄資料，包含模型參數設置、額外圖表以及公式。

5.4.1 模型參數設置

表 ?? 列出了模型訓練過程中的關鍵參數設置。

表 I: 模型訓練配置參數

參數	值
批次大小 (Batch Size)	16
學習率 (Learning Rate)	2e-5
訓練輪數 (Epochs)	3
優化器 (Optimizer)	AdamW
權重衰減	$weightdecay = 0.01$
最大 Token 長度	256

5.4.2 圖表與結果分析

圖 I 為數據分布的示例圖表，展示了數據集樣本的長度分布。

數據集	文件	文件標識	年份範圍	判例數量 (單一PDF)	共計
Data1	a-c	a1-c10	1891-01-01 ~ 1991-10-01	b2, c2 : 93個判例，其餘100個判例	2986個判例
Data2	e-g	e1-g10	1998-09-14 ~ 2009-04-23	f2, g2 : 99個判例，其餘100個判例	2998個判例
Data3	h-j	h1-j10	2009-04-23 ~ 2017-07-05	h2 : 98個判例，i2 : 99個判例，其餘100個判例	3302個判例
	k	K1-k4	2021-08-31 ~ 2022-12-31	k1 : 5個判例，其餘100個判例	
Supreme Court	d	d1-d19	1891-01-01 ~ 2022-12-31	1 個判例	19個判例
總計	a-k	A1-k4	1891-01-01 ~ 2022-12-31		共9305個判例

圖 I: 數據分布示例圖

5.4.3 公式展示

公式 I 定義了交叉熵損失函數，該函數在模型訓練中用於最小化預測值與目標值之間的差異。

$$\text{Loss} = - \sum_{i=1}^N [y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i)] \quad (\text{I})$$

5.4.4 補充說明

附錄部分補充的圖表與公式進一步支持了研究的結論，強調了模型的性能優勢與訓練過程的可靠性。